



**UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS**

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

**Maestría en Ingeniería de Sistemas e Informática con mención en  
Ingeniería de Software**

***SÍLABO***

Nombre de la asignatura : MACHINE LEARNING Y BIG DATA

Profesor responsable : Mg. Juan Gamarra Moreno

Correo electrónico : [juan.gamarra@unmsm.edu.pe](mailto:juan.gamarra@unmsm.edu.pe)

2024-2



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

### 1. INFORMACIÓN GENERAL

1.1	Nombre de la asignatura	:	MACHINE LEARNING Y BIG DATA
1.2	Tipo de asignatura	:	Obligatoria
1.3	Profesor	:	Mg. Juan Gamarra Moreno
1.4	Programa	:	Maestría en Ingeniería de Sistemas e Informática con mención en Ingeniería de Software
1.5	Código de asignatura	:	R3P2A111, R3S2A111
1.6	Créditos	:	4
1.7	N° de horas semanales	:	3
1.8	N° de horas por semestre	:	48
1.9	Semestre académico	:	2024-2
1.10	Duración	:	16 semanas
1.11	Fecha de inicio	:	14 de septiembre de 2024
1.12	Fecha de finalización	:	02 de enero de 2025
1.13	Horario	:	Sábados 3:00 p.m.-6:00 p.m.

### 2. FUNDAMENTOS DE LA ASIGNATURA

#### 2.1. Sumilla.

Asignatura que corresponde al periodo Profundización, es de naturaleza Teórica-práctica de modalidad presencial. Tiene el propósito de brindar los conocimientos para la predicción de patrones en grandes volúmenes de información estructurados y no estructurados, aglomerados en bases de datos o dispersos en diversos formatos en internet. Abarca los siguientes aspectos: Modelado de datos, Datawarehouse, Análisis multidimensional, Técnicas Data Mining, aprendizaje automático supervisado y no supervisado, Cloud Computing, Big data. Culmina con una aplicación práctica. Al finalizar el estudiante deberá presentar un informe aplicando los tópicos tratados.

Las unidades son:

- Patrones
- Modelado de datos
- Análisis multidimensional
- Técnicas Data Mining

#### 2.2. Competencias del programa.

El curso contribuye al logro de competencias, tales como:

- 2.2.1. Realizar investigación de alto nivel académico en al menos una de las líneas de investigación del programa.
- 2.2.2. Identificar y adoptar tecnologías disruptivas basadas en Gestión de la Información y del Conocimiento para la transformación digital de la organización.
- 2.2.3. Aplicar el análisis crítico y pensamiento creativo para la identificación y solución de problemas de la organización con tecnologías emergentes de Gestión de la Información y del Conocimiento.



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

### 2.3. Competencias de la asignatura.

- 2.3.1. Comprende los fundamentos teóricos de Machine Learning y Big Data, aplicando técnicas de preprocesamiento y algoritmos de regresión, clasificación y agrupamiento para resolver problemas, mientras se actúa con responsabilidad ética al manejar datos masivos, asegurando la privacidad y minimizando sesgos en los modelos.
- 2.3.2. Usa algoritmos avanzados como redes neuronales profundas, Deep Learning y modelos Transformers, implementando soluciones efectivas con herramientas y tecnologías adecuadas, manteniendo una actitud innovadora y colaborativa en la resolución de problemas complejos mediante tecnologías emergentes.
- 2.3.3. Despliega modelos de Machine Learning en producción, optimizando su rendimiento en entornos reales utilizando plataformas adecuadas y la nube, y promoviendo una mentalidad crítica, ética y proactiva en la automatización, el monitoreo continuo y la mejora de modelos de inteligencia artificial.

## 3. CONTENIDO TEMÁTICO

### 3.1. Unidad de Aprendizaje 1: Fundamentos y Modelos Clásicos de Machine Learning

#### Competencias de la asignatura

- Comprende los fundamentos teóricos de Machine Learning y Big Data, aplicando técnicas de preprocesamiento y algoritmos de regresión, clasificación y agrupamiento para resolver problemas, mientras se actúa con responsabilidad ética al manejar datos masivos, asegurando la privacidad y minimizando sesgos en los modelos.

#### Logros de aprendizaje:

- Explicar los fundamentos teóricos de Machine Learning y Big Data, comprendiendo sus principios, tipos de aprendizaje (supervisado y no supervisado) y sus aplicaciones en diferentes industrias.
- Preprocesar datos para su uso en modelos de Machine Learning, aplicando técnicas como la limpieza, normalización, estandarización y codificación de variables utilizando herramientas como Python y bibliotecas como Pandas y Scikit-learn.
- Implementar algoritmos clásicos de Machine Learning supervisado, como regresión lineal y clasificación (Regresión Logística, KNN), evaluando su rendimiento mediante métricas adecuadas en datasets reales.
- Aplicar algoritmos no supervisados, como K-Means y clustering jerárquico, para analizar datos no etiquetados, evaluando la calidad de los clusters generados a través de métodos como Elbow y Silhouette Score.
- Desarrollar redes neuronales artificiales básicas (ANN), aplicando funciones de activación y retropropagación, y evaluando su rendimiento en problemas de clasificación de datos.
- Actuar con responsabilidad ética en el manejo de datos, asegurando la privacidad y minimizando los sesgos durante el preprocesamiento y la implementación de modelos de Machine Learning.



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

### Contenido Temático:

<b>Semana 1: Introducción a Machine Learning y Big Data</b> Teoría: <ul style="list-style-type: none"><li>Definiciones de Machine Learning (ML) y Big Data.</li><li>Diferencias y similitudes entre ML y Big Data.</li><li>Aplicaciones en el mundo real.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>Configuración del entorno de trabajo con Python.</li><li>Introducción a las bibliotecas esenciales (Pandas, NumPy, Scikit-learn).</li></ul>
<b>Semana 2: Preprocesamiento de Datos</b> Teoría: <ul style="list-style-type: none"><li>Limpieza de datos: manejo de datos faltantes, duplicados, y transformación de datos.</li><li>Normalización, estandarización y codificación de variables.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>Preprocesamiento de un dataset real utilizando Pandas y Scikit-learn.</li></ul>
<b>Semana 3: Aprendizaje Supervisado - Regresión Lineal</b> Teoría: <ul style="list-style-type: none"><li>Introducción a los modelos de regresión (Regresión Lineal, Regularización: Ridge, Lasso).</li><li>Evaluación del modelo: métricas de rendimiento (MSE, <math>R^2</math>).</li></ul> Laboratorio: <ul style="list-style-type: none"><li>Implementación de un modelo de regresión lineal en Python con Scikit-learn.</li><li>Evaluación y ajuste del modelo con diferentes técnicas de regularización.</li></ul>
<b>Semana 4: Aprendizaje Supervisado - Clasificación</b> Teoría: <ul style="list-style-type: none"><li>Modelos de clasificación (Regresión Logística, KNN, Support Vector Machines).</li><li>Métricas de evaluación: Precisión, Recall, F1-Score.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>Implementación de un modelo de clasificación utilizando Regresión Logística.</li><li>Interpretación de resultados con métricas de evaluación.</li></ul>
<b>Semana 5: Árboles de Decisión y Random Forest</b> Teoría: <ul style="list-style-type: none"><li>Introducción a Árboles de Decisión.</li><li>Conceptos de sobreajuste y técnicas para evitarlo.</li><li>Introducción a Random Forest y su uso en problemas de clasificación y regresión.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>Implementación de Árboles de Decisión y Random Forest.</li><li>Comparación de rendimiento entre ambos modelos.</li></ul>
<b>Semana 6: Aprendizaje No Supervisado - Clustering</b> Teoría: <ul style="list-style-type: none"><li>Introducción al Clustering: K-Means, DBSCAN, Clustering Jerárquico.</li><li>Métodos de evaluación: Silhouette Score, Elbow Method.</li></ul> Laboratorio:



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

<ul style="list-style-type: none"><li>• Implementación de K-Means Clustering en un dataset no etiquetado.</li><li>• Visualización y análisis de los clusters generados.</li></ul>
<b>Semana 7: Redes Neuronales Artificiales (ANN)</b> Teoría: <ul style="list-style-type: none"><li>• Fundamentos de las redes neuronales: estructura, funciones de activación, y retropropagación.</li><li>• Redes Neuronales frente a otros modelos de ML.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Implementación de una red neuronal básica usando TensorFlow/Keras.</li><li>• Entrenamiento y evaluación de una ANN para clasificación.</li></ul>
<b>Semana 8: Evaluación Parcial</b> <ul style="list-style-type: none"><li>• Examen teórico y práctico sobre los temas cubiertos en las semanas anteriores.</li><li>• El examen práctico consistirá en implementar y ajustar un modelo de ML basado en un dataset proporcionado.</li></ul>

### 3.2. Unidad de Aprendizaje 2: Técnicas Avanzadas y Aplicaciones en Producción

#### Competencias de la asignatura

- Usa algoritmos avanzados como redes neuronales profundas, Deep Learning y modelos Transformers, implementando soluciones efectivas con herramientas y tecnologías adecuadas, manteniendo una actitud innovadora y colaborativa en la resolución de problemas complejos mediante tecnologías emergentes.
- Despliega modelos de Machine Learning en producción, optimizando su rendimiento en entornos reales utilizando plataformas adecuadas y la nube, y promoviendo una mentalidad crítica, ética y proactiva en la automatización, el monitoreo continuo y la mejora de modelos de inteligencia artificial.

#### Logros de aprendizaje:

- Explicar los principios avanzados de Deep Learning, comprendiendo el funcionamiento de redes neuronales profundas (ANN, CNN) y su aplicación en tareas de clasificación de imágenes y otros datos complejos.
- Implementar redes neuronales convolucionales (CNN) para la clasificación de imágenes, utilizando bibliotecas como TensorFlow y Keras, y evaluar su rendimiento utilizando datasets como MNIST.
- Utilizar herramientas de procesamiento de datos masivos (Big Data), como Hadoop y Spark, para procesar grandes volúmenes de datos de manera eficiente, aplicando técnicas de paralelización y procesamiento distribuido.
- Desarrollar modelos de aprendizaje automático distribuidos utilizando Spark MLlib, implementando algoritmos escalables y optimizando el rendimiento en entornos de Big Data.
- Aplicar modelos de procesamiento de lenguaje natural (NLP) basados en Transformers, como BERT o GPT, ajustando modelos preentrenados y evaluando su rendimiento en tareas como clasificación de texto o análisis de sentimientos.
- Desplegar modelos de Machine Learning en producción, utilizando herramientas como Flask o FastAPI para crear APIs y monitorear el rendimiento de los modelos en entornos reales.



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

- Adoptar prácticas de MLOps para gestionar el ciclo de vida de los modelos de Machine Learning en producción, incluyendo el monitoreo, mantenimiento y actualización continua de los modelos.
- Demostrar una actitud crítica y ética en el uso de modelos avanzados de Machine Learning y Big Data, asegurando la equidad, transparencia y minimización de sesgos en los resultados, y considerando el impacto de estos modelos en la sociedad.

### Contenido Temático:

<b>Semana 9: Introducción a Deep Learning y Redes Convolucionales (CNN)</b> Teoría: <ul style="list-style-type: none"><li>• Introducción a Deep Learning y redes neuronales profundas.</li><li>• Introducción a las CNN: estructura y casos de uso.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Implementación básica de una CNN para clasificación de imágenes (MNIST dataset).</li></ul>
<b>Semana 10: Procesamiento de Datos Masivos con Big Data</b> Teoría: <ul style="list-style-type: none"><li>• Introducción a las arquitecturas de Big Data: Hadoop, Spark.</li><li>• Modelos de procesamiento: Batch Processing vs Stream Processing.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Introducción a PySpark para el procesamiento de grandes volúmenes de datos.</li><li>• Análisis de un dataset masivo con Spark.</li></ul>
<b>Semana 11: Aprendizaje Automático Distribuido</b> Teoría: <ul style="list-style-type: none"><li>• Escalabilidad en Machine Learning.</li><li>• Técnicas de paralelización y procesamiento distribuido.</li><li>• Introducción a MLlib de Apache Spark.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Implementación de algoritmos de ML distribuidos con Spark MLlib.</li><li>• Comparación de rendimiento en datasets masivos.</li></ul>
<b>Semana 12: Procesamiento de Lenguaje Natural (NLP)</b> Teoría: <ul style="list-style-type: none"><li>• Introducción a NLP: tokenización, lematización, y modelos de lenguaje.</li><li>• Aplicación de redes neuronales en NLP (Word2Vec, embeddings).</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Implementación de modelos básicos de NLP usando NLTK y SpaCy.</li><li>• Análisis de sentimientos en textos con ML.</li></ul>
<b>Semana 13: Redes Generativas Antagónicas (GANs)</b> Teoría: <ul style="list-style-type: none"><li>• Introducción a GANs: generadores y discriminadores.</li><li>• Aplicaciones de GANs en la generación de datos sintéticos.</li></ul> Laboratorio: <ul style="list-style-type: none"><li>• Implementación básica de una GAN usando TensorFlow/Keras.</li><li>• Generación de imágenes sintéticas a partir de ruido.</li></ul>



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

### **Semana 14: Introducción a Transformers y Modelos Preentrenados**

#### Teoría:

- Introducción a la arquitectura Transformer: mecanismo de atención, auto-atención, capas de codificador y decodificador.
- Ventajas de los Transformers frente a modelos anteriores (RNN, LSTM) en procesamiento de secuencias.
- Modelos preentrenados basados en Transformers: BERT, GPT, T5, entre otros.
- Aplicaciones prácticas: clasificación de texto, generación de texto, traducción automática, y análisis de sentimientos.

#### Laboratorio:

- Uso de la biblioteca Hugging Face para trabajar con modelos preentrenados.
- Carga de un modelo preentrenado como BERT o GPT.
- Ajuste fino (fine-tuning) en un dataset específico, como una tarea de clasificación de texto o análisis de sentimientos.
- Evaluación de métricas de rendimiento y comparación con otros modelos.

### **Semana 15: Implementación de Modelos de ML en Producción**

#### Teoría:

- Ciclo de vida de un modelo de ML en producción: desde el desarrollo hasta el despliegue.
- Consideraciones prácticas: rendimiento, escalabilidad, y mantenimiento de modelos en entornos reales.
- Introducción a MLOps: cómo gestionar el desarrollo, el despliegue y el mantenimiento de modelos a gran escala.
- Herramientas para despliegue: Flask, FastAPI, Docker, y plataformas en la nube (AWS, Google Cloud, Azure).

#### Laboratorio:

- Desarrollo de una API sencilla para servir un modelo de ML utilizando Flask o FastAPI.
- Despliegue de un modelo en un entorno local o en la nube (puede usarse Google Cloud o AWS).
- Creación de endpoints para la predicción en tiempo real.
- Implementación de un pipeline para monitorizar el rendimiento del modelo en producción.

### **Semana 16: Evaluación Final**

- Examen teórico y práctico sobre los temas de las semanas 9 a 15.
- El examen práctico consistirá en desarrollar y desplegar un modelo de ML o Transformer aplicado a un problema real, incluyendo preprocesamiento, entrenamiento y despliegue en producción.

### **3.3. Bibliografía.**

- Navlani A., Fandango A., Idris I. (2021), “Python Data Analysis”, 3rd Ed, Packt.
- Zhang A. (2017), Data Analytics. Practical Guide to Leveraging the Power of Algorithms, Data Science, Data Mining, Statistics, Big Data, and Predictive Analysis to Improve Business, Work, and Life
- James G., Witten D., Hastie T. Tibshirani R. (2013), “An Introduction to Statistical Learning with Applications in R”, Springer.



## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

- Montgomery D., Peck E., Vining G. (), “Introduction to Linear Regression Analysis”, 5th Ed, Wiley.
- Bobadilla J. (2020). “Machine Learning y Deep Learning. Usando Python, Scikit y Keras”, Ra-Ma.
- Albon C. (2018) “Machine Learning with Python Cookbook. Practical Solutions from Preprocessing to Deep Learning”, 1st, Ed. O’Reilly.
- Fuentes A. (2018), “Hands-On Predictive Analytics with Python”, Packt.
- Tan P., Steinbach M., Kumar V., Karpatne A. (2019), “Introduction to Data Mining”, 2nd Ed., Pearson Education.
- Grus J. (2019). “Data Science from Scratch”, 2nd Ed., O’Reilly
- Müller A., Guido S. (2017). “Introduction to Machine Learning with Python”, 1st Ed. O’Reilly.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications.
- Zaharia, M., & Wendell, P. (2020). Learning Spark: Lightning-Fast Data Analytics (2nd ed.). O’Reilly Media.
- Vaswani, A., et al. (2017). Attention is All You Need. NeurIPS Conference.
- Geron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.). O’Reilly Media.

### Recursos Electrónicos

- **TensorFlow**  
Recurso oficial de Google para aprender y aplicar Machine Learning y Deep Learning con TensorFlow. Incluye tutoriales, guías y ejemplos.  
<https://www.tensorflow.org/>
- **Scikit-learn**  
Biblioteca de Python para Machine Learning. La documentación oficial proporciona guías prácticas, ejemplos y referencias sobre algoritmos de aprendizaje supervisado y no supervisado.  
<https://scikit-learn.org/stable/>
- **Apache Spark**  
Página oficial de Apache Spark, una plataforma de procesamiento distribuido utilizada en Big Data. Incluye documentación, guías de instalación y tutoriales.  
<https://spark.apache.org/>
- **Hugging Face**  
Plataforma líder en modelos preentrenados basados en Transformers (BERT, GPT, etc.). Proporciona acceso a modelos, datasets y guías para ajustar y desplegar modelos de NLP.  
<https://huggingface.co/>
- **Kaggle**  
Plataforma para ciencia de datos que ofrece datasets gratuitos, tutoriales y competiciones de Machine Learning. Excelente recurso para obtener datasets y practicar con modelos.





## UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

<https://www.kaggle.com/>

- **Google Cloud - Big Data and Machine Learning Products**  
Documentación y guías sobre cómo utilizar las herramientas de Big Data y Machine Learning en Google Cloud, incluyendo BigQuery, AutoML, y AI Platform.  
<https://cloud.google.com/products/ai>
- **Coursera - Machine Learning by Stanford University**  
Curso en línea impartido por Andrew Ng, uno de los cursos más recomendados para aprender los fundamentos de Machine Learning.  
<https://www.coursera.org/learn/machine-learning>

#### 4. ESTRATEGIAS METODOLÓGICAS

La metodología de enseñanza es semi presencial, los contenidos y material de enseñanza se publicarán en el Aula Virtual de la Unidad de Posgrado, la sesión de clase se desarrollará mediante videoconferencias en línea (síncronos) y con sesiones presenciales según la programación horaria del curso. Entre las estrategias de enseñanza a utilizar se tiene: La clase magistral, discusión grupal, aprendizaje basado en problemas ABP, aprendizaje basado en proyectos, asesoría, y talleres. El presente curso utilizará Microsoft Teams para videoconferencias y para pizarra electrónica Microsoft Whiteboard.

#### 5. ESTRATEGIAS DE EVALUACIÓN

##### 5.1. Modalidades de evaluación:

La Modalidad de evaluación comprende; solución a problemas propuestos, entregables del artículo que deberán ser presentados mediante la plataforma del Aula Virtual, asimismo las exposiciones de trabajos deberán realizarse mediante videoconferencias en línea cuyos enlaces a sus contenidos deberán registrarse en la plataforma del Aula Virtual

##### 5.2. Criterios de evaluación

Se consideran como trabajos los ejercicios propuestos en las sesiones de clase.

Ponderaciones:

Modalidades	Porcentaje
N1 Trabajos desde la semana 1 hasta la semana 7.	30%
N2 Trabajos desde la semana 9 hasta la semana 15	30%
N3 Evaluación Parcial	20%
N4 Evaluación Final	20%
Total	100%

$$NF = 30\% N1 + 30\% N2 + 20\% N3 + 20\% N4$$

**Nota aprobatoria mínima: 14**



**UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS**

Universidad del Perú. Decana de América  
Facultad de Ingeniería de Sistemas e Informática  
Vicedecanato de Investigación y Posgrado  
Unidad de Posgrado

**5.3. Requisitos para aprobar la asignatura:**

- Es un requisito contar con asistencia mayor o igual al 70% las cuales serán registradas por el docente en el SUM (Sistema Único de Matricula) según la programación académica.
- Obtener un promedio final mayor o igual a 14.

*Ciudad Universitaria, Septiembre del 2024*