


Python para Ciencia de Datos y Aprendizaje de Máquinas

DATA SCIENCE SKILLSET



Data science, due to its interdisciplinary nature, requires an intersection of abilities: **hacking skills**, **math and statistics knowledge**, and **substantive expertise** in a field of science.



Hacking skills are necessary for working with massive amounts of electronic data that must be acquired, cleaned, and manipulated.



Math and statistics knowledge allows a data scientist to choose appropriate methods and tools in order to extract insight from data.



Substantive expertise in a scientific field is crucial for generating motivating questions and hypotheses and interpreting results.



Traditional research lies at the intersection of knowledge of math and statistics with substantive expertise in a scientific field.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Hacking skills are necessary for working with massive amounts of electronic data that must be acquired, cleaned, and manipulated.



Math and statistics knowledge allows a data scientist to choose appropriate methods and tools in order to extract insight from data.



Substantive expertise in a scientific field is crucial for generating motivating questions and hypotheses and interpreting results.



Traditional research lies at the intersection of knowledge of math and statistics with substantive expertise in a scientific field.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



Math and statistics knowledge allows a data scientist to choose appropriate methods and tools in order to extract insight from data.



Substantive expertise in a scientific field is crucial for generating motivating questions and hypotheses and interpreting results.



Traditional research lies at the intersection of knowledge of math and statistics with substantive expertise in a scientific field.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



El **conocimiento matemático y estadístico** permite que un científico de datos elija los métodos y herramientas adecuados para extraer información de los datos.



Substantive expertise in a scientific field is crucial for generating motivating questions and hypotheses and interpreting results.



Traditional research lies at the intersection of knowledge of math and statistics with substantive expertise in a scientific field.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



El **conocimiento matemático y estadístico** permite que un científico de datos elija los métodos y herramientas adecuados para extraer información de los datos.



La **experiencia sustantiva** en un campo científico es crucial para generar preguntas motivadoras e hipótesis e interpretar los resultados.



Traditional research lies at the intersection of knowledge of math and statistics with substantive expertise in a scientific field.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



El **conocimiento matemático y estadístico** permite que un científico de datos elija los métodos y herramientas adecuados para extraer información de los datos.



La **experiencia sustantiva** en un campo científico es crucial para generar preguntas motivadoras e hipótesis e interpretar los resultados.



La **investigación tradicional** se encuentra en la intersección del conocimiento de matemáticas y estadística con experiencia sustantiva en un campo científico.




Machine learning stems from combining hacking skills with math and statistics knowledge, but does not require scientific motivation.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



El **conocimiento matemático y estadístico** permite que un científico de datos elija los métodos y herramientas adecuados para extraer información de los datos.



La **experiencia sustantiva** en un campo científico es crucial para generar preguntas motivadoras e hipótesis e interpretar los resultados.



La **investigación tradicional** se encuentra en la intersección del conocimiento de matemáticas y estadística con experiencia sustantiva en un campo científico.




El **aprendizaje automático** se deriva de la combinación de las habilidades de hacking con las matemáticas y el conocimiento estadístico, pero no requiere motivación científica.



Danger zone! Hacking skills combined with substantive scientific expertise without rigorous methods can beget incorrect analyses.

CONJUNTO DE HABILIDADES EN DATA SCIENCE



La ciencia de datos, debido a su naturaleza interdisciplinaria, requiere una intersección de habilidades: **habilidades de hacking, conocimiento de matemáticas y estadística, y experiencia sustantiva** en un campo de la ciencia.



Las **habilidades de hacking** son necesarias para trabajar con grandes cantidades de datos electrónicos que se deben adquirir, limpiar y manipular.



El **conocimiento matemático y estadístico** permite que un científico de datos elija los métodos y herramientas adecuados para extraer información de los datos.



La **experiencia sustantiva** en un campo científico es crucial para generar preguntas motivadoras e hipótesis e interpretar los resultados.



La **investigación tradicional** se encuentra en la intersección del conocimiento de matemáticas y estadística con experiencia sustantiva en un campo científico.




El **aprendizaje automático** se deriva de la combinación de las habilidades de hacking con las matemáticas y el conocimiento estadístico, pero no requiere motivación científica.



¡Zona peligrosa! Las habilidades de hackings combinadas con la experiencia científica sustantiva sin métodos rigurosos pueden obtener un análisis incorrecto.

Python, R, Both, or Other platforms for Analytics, Data Science, Machine Learning



What does a data scientist do?



Data driven
Products

Reports
Visualization
Blogs

Raw Data

Processing
↓

Dataset

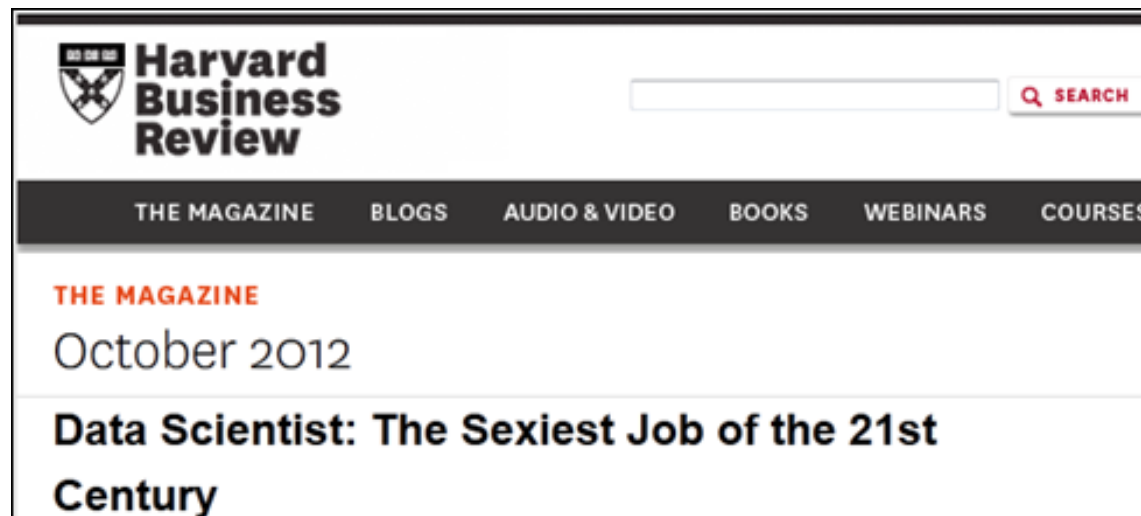
Statistical
Models / Analysis

Machine Learning
Predictions




Data Scientist

- Reconocido como uno de los mejores trabajos
- Grandes Salarios
- Solución de problemas interesantes



Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark



NumPy

[Scipy.org](https://scipy.org)

NumPy


NumPy is the fundamental package for scientific computing with Python. It contains among other things:

- a powerful N-dimensional array object
- sophisticated (broadcasting) functions
- tools for integrating C/C++ and Fortran code
- useful linear algebra, Fourier transform, and random number capabilities

Besides its obvious scientific uses, NumPy can also be used as an efficient multi-dimensional container of generic data. Arbitrary data-types can be defined. This allows NumPy to seamlessly and speedily integrate with a wide variety of databases.

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark





Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark

pandas

$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$




Python Data Analysis
Library

pandas is an open source, BSD-licensed library providing high-performance, easy-to-use data structures and data analysis tools for the Python programming language.

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark

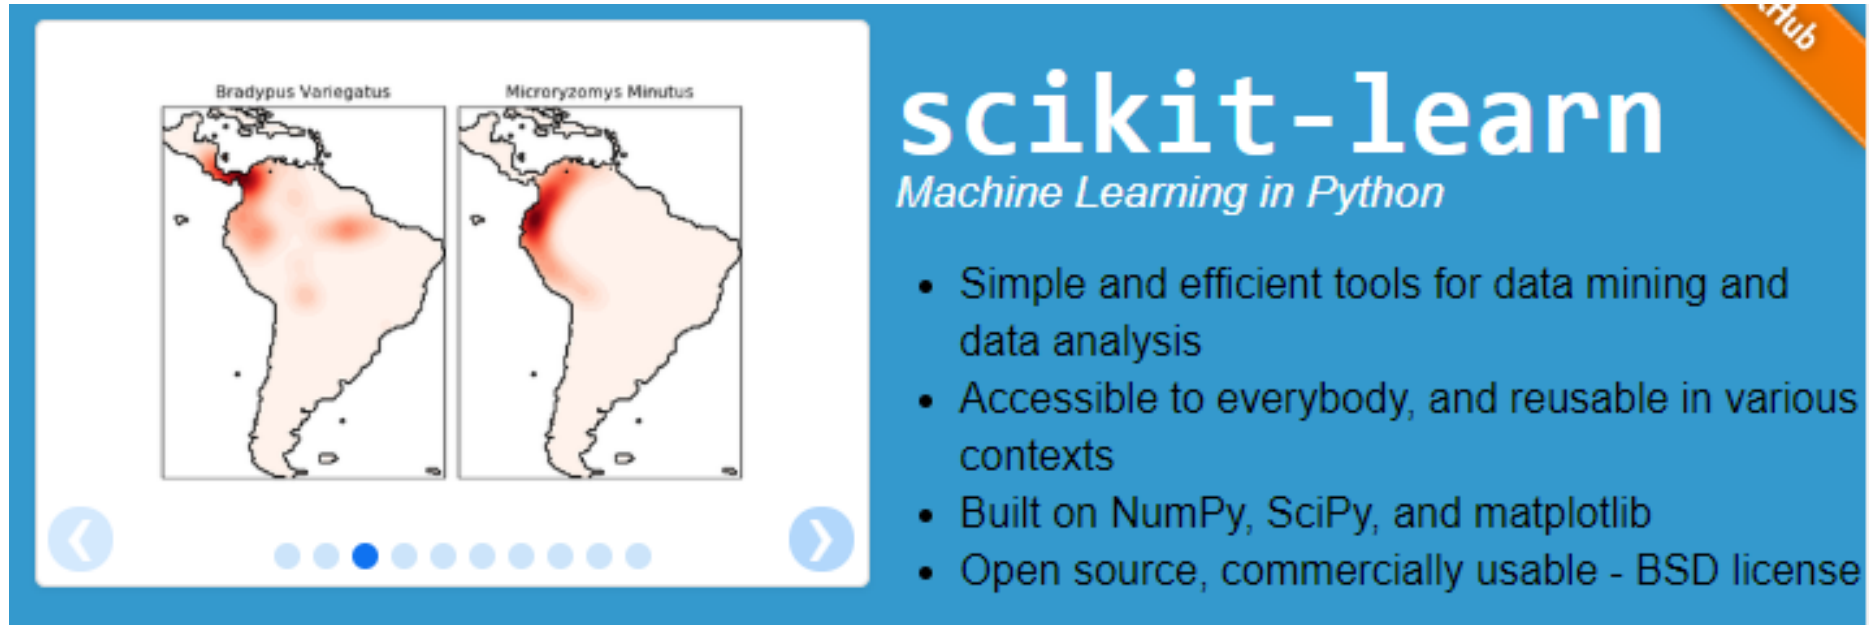
seaborn: statistical data visualization



Seaborn is a Python visualization library based on matplotlib. It provides a high-level interface for drawing attractive statistical graphics.

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark



scikit-learn
Machine Learning in Python

- Simple and efficient tools for data mining and data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark



Classification

Identifying to which category an object belongs to.

Applications: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors, random forest, ... — Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, ridge regression, Lasso, ... — Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... — Examples

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency

Algorithms: PCA, feature selection, non-negative matrix factorization. — Examples

Model selection

Comparing, validating and choosing parameters and models.

Goal: Improved accuracy via parameter tuning

Modules: grid search, cross validation, metrics. — Examples

Preprocessing

Feature extraction and normalization.

Application: Transforming input data such as text for use with machine learning algorithms.

Modules: preprocessing, feature extraction. — Examples





Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark



[home](#) | [examples](#) | [tutorials](#) | [pyplot](#) | [docs](#) »

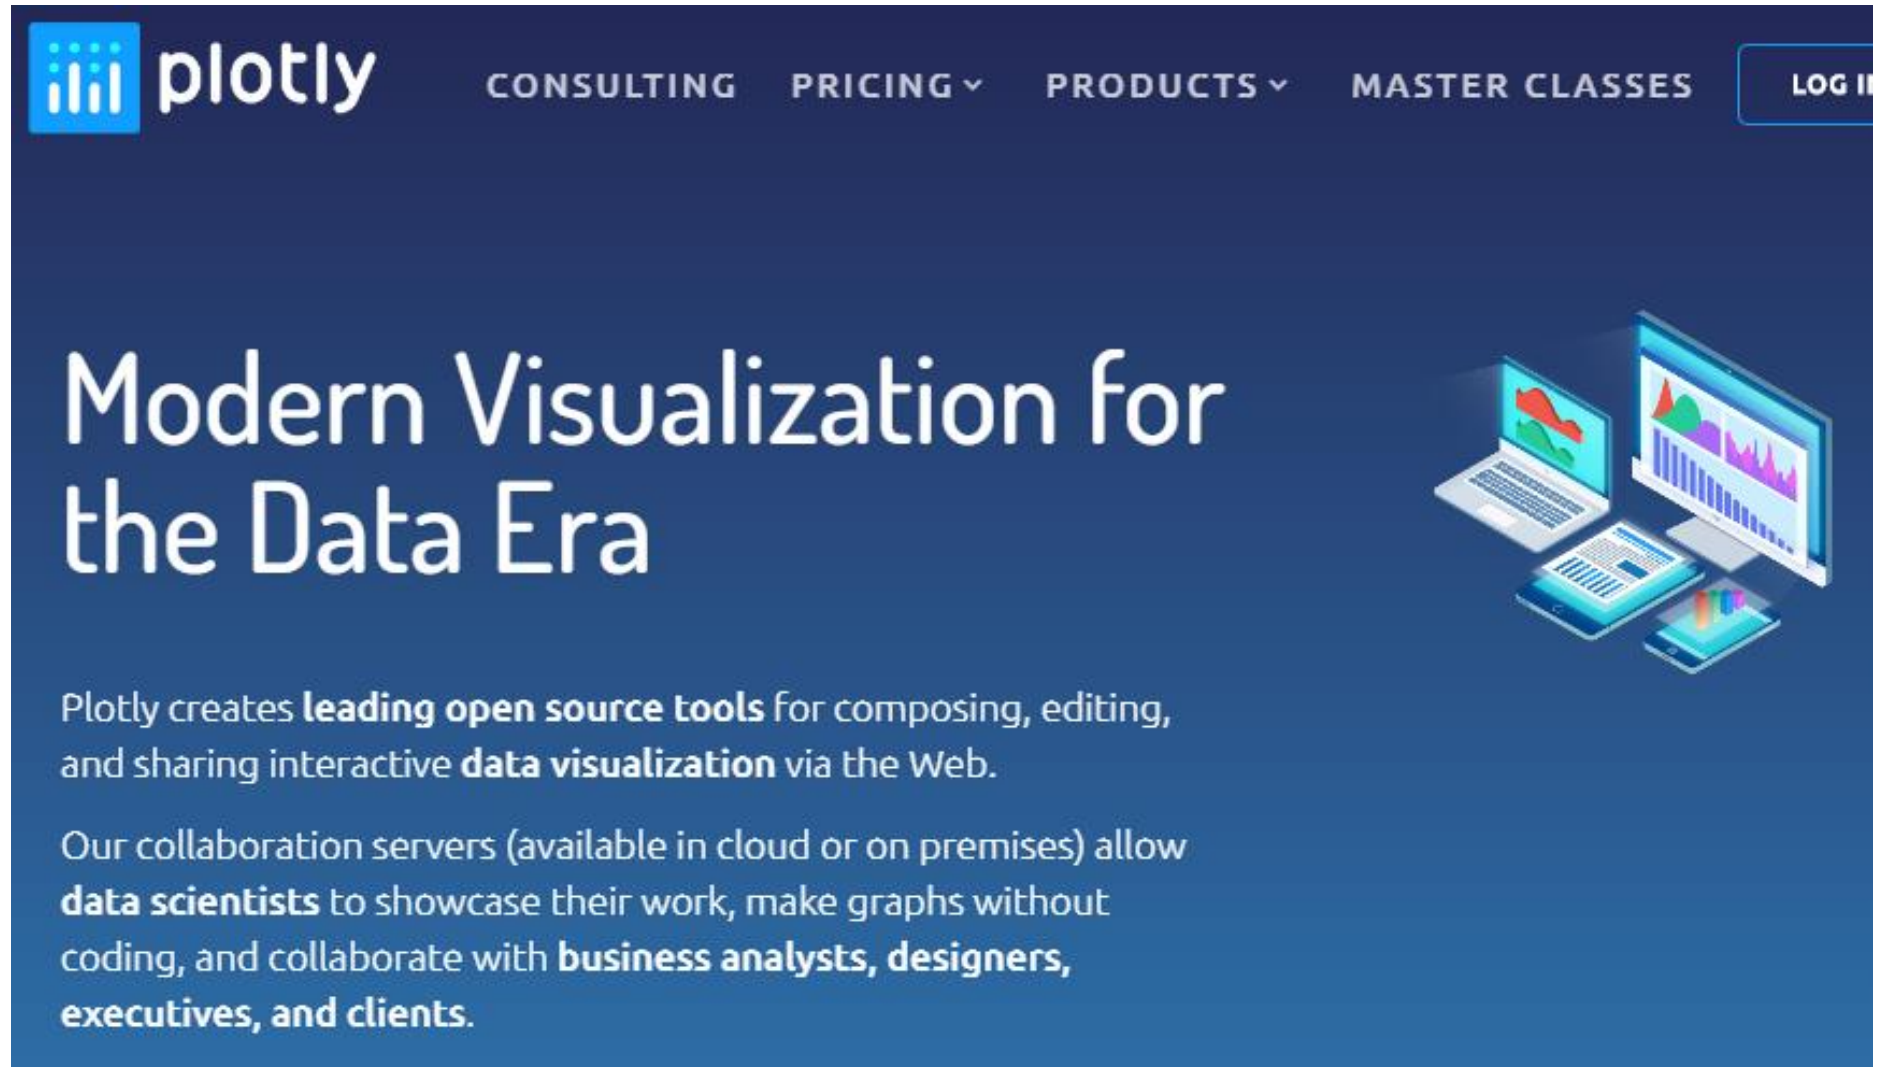
Matplotlib is a Python 2D plotting library which produces publication quality figures in a variety of hardcopy formats and interactive environments across platforms. Matplotlib can be used in Python scripts, the Python and IPython shells, the Jupyter notebook, web application servers, and four graphical user interface toolkits.



Matplotlib tries to make easy things easy and hard things possible. You can generate plots, histograms, power spectra, bar charts, errorcharts, scatterplots, etc., with just a few lines of code. For examples, see the [sample](#)

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark

The image shows the Plotly website banner. At the top left is the Plotly logo, which consists of a blue square with three white vertical bars of increasing height, followed by the word "plotly" in white lowercase letters. To the right of the logo are navigation links: "CONSULTING", "PRICING", "PRODUCTS", and "MASTER CLASSES", each with a small downward arrow. Further right is a "LOG IN" button. The main heading "Modern Visualization for the Data Era" is in large white text. Below it is a paragraph: "Plotly creates **leading open source tools** for composing, editing, and sharing interactive **data visualization** via the Web." Another paragraph follows: "Our collaboration servers (available in cloud or on premises) allow **data scientists** to showcase their work, make graphs without coding, and collaborate with **business analysts, designers, executives, and clients.**" On the right side of the banner is an illustration of a laptop, a desktop monitor, and two smartphones, all displaying various data visualizations like bar charts, line graphs, and area charts in vibrant colors.

plotly CONSULTING PRICING PRODUCTS MASTER CLASSES LOG IN

Modern Visualization for the Data Era

Plotly creates **leading open source tools** for composing, editing, and sharing interactive **data visualization** via the Web.

Our collaboration servers (available in cloud or on premises) allow **data scientists** to showcase their work, make graphs without coding, and collaborate with **business analysts, designers, executives, and clients.**

Librerías mas populares para ciencias de datos en Python

- NumPy
- SciPy
- Pandas
- Seaborn
- scikit-learn
- Matplotlib
- Plotly
- PySpark



Configuración de Entorno

- En este taller usaremos Notebooks de Jupyter.
- Sin embargo usted es libre de usar el entorno de desarrollo que prefiera.
- Todas las notas pueden ser descargadas como archivos .py que son compatibles con cualquier IDE de Python o editor de texto.
- Usaremos la última versión de Python 3 a través de la distribución de Anaconda



notebook

↗ 5.4.0

Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis.



spyder

3.2.8


Scientific PYthon Development EnviRonment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features

Instalación de Anaconda Navigator

Desinstalar cualquier versión previa de Python, antes de instalar Anaconda.



Es muy importante considerar esta opción en la instalación para poder seguir los mismos pasos en los ejemplos





Applications on

base (root) ▾

Channels

[Refresh](#)

jupyterlab

[0.31.4](#)

An extensible environment for interactive and reproducible computing, based on the Jupyter Notebook and Architecture.

[Launch](#)

notebook

5.4.0

Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis.

[Launch](#)

qtconsole

4.3.1

PyQt GUI that supports inline figures, proper multiline editing with syntax highlighting, graphical calltips, and more.

[Launch](#)

spyder

3.2.6


Scientific PYTHON Development Environment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features

[Launch](#)

vscode

1.21.1

Streamlined code editor with support for development operations like debugging, task running and version control.



glueviz

0.12.0

Multidimensional data visualization across files. Explore relationships within and among related datasets.



orange3

3.4.1

Component based data mining framework. Data visualization and data analysis for novice and expert. Interactive workflows

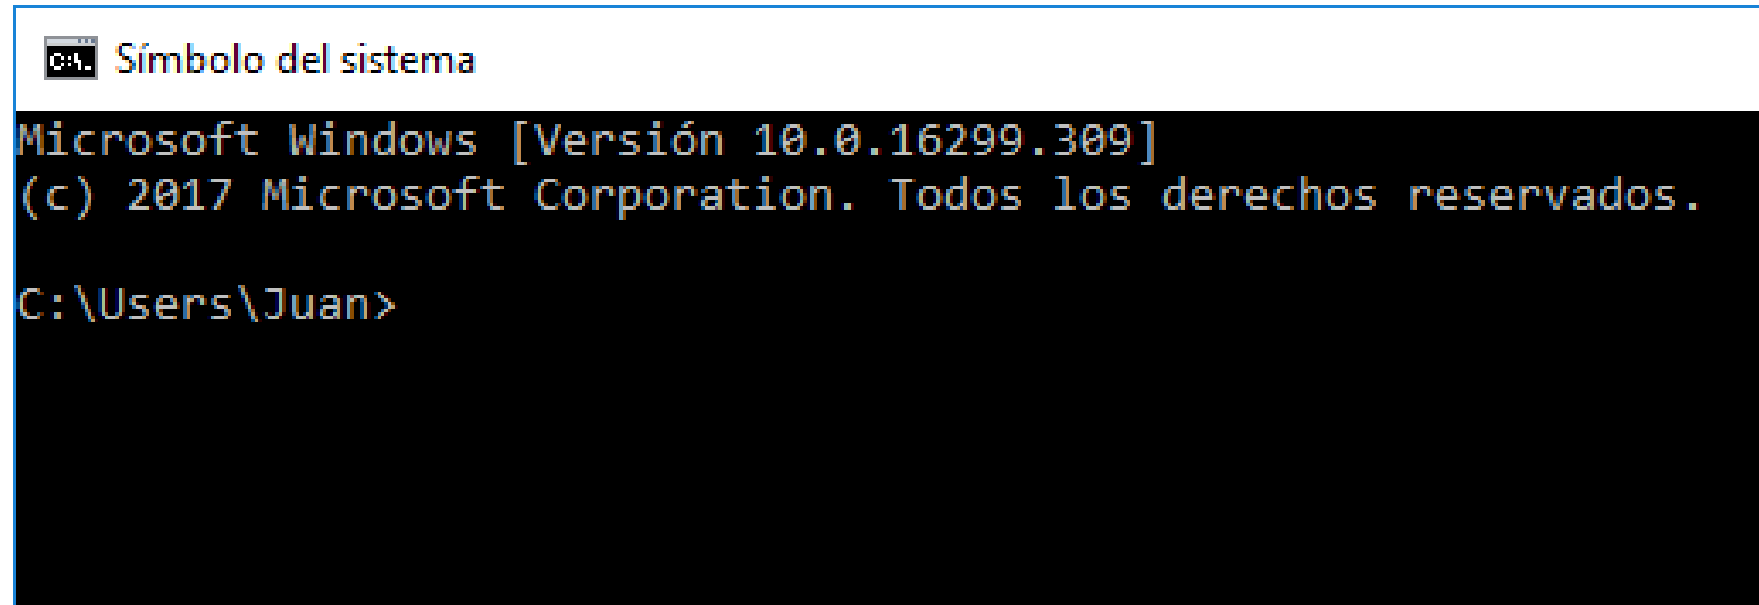


rstudio

1.1.383

A set of integrated tools designed to help you be more productive with R. Includes R essentials and notebooks.

Comprobar la
instalación
adecuada con la
ventana de
Símbolo del
Sistema


A screenshot of a Windows Command Prompt window titled "Símbolo del sistema". The window has a black background with white text. The text displayed is: "Microsoft Windows [Versión 10.0.16299.309]" on the first line, "(c) 2017 Microsoft Corporation. Todos los derechos reservados." on the second line, and "C:\Users\Juan>" on the third line, indicating the current directory and the command prompt character.

```
Microsoft Windows [Versión 10.0.16299.309]
(c) 2017 Microsoft Corporation. Todos los derechos reservados.
C:\Users\Juan>
```


Si tiene creado
en la unidad C
las siguientes
carpetas:

Cambiar a la
carpeta
correspondiente

Este equipo ➤ OS (C:) ➤ CursoML

 Símbolo del sistema - jupyter notebook

```
Microsoft Windows [Versión 10.0.17134.165]
(c) 2018 Microsoft Corporation. Todos los derechos reservados.

C:\Users\Juan>cd..

C:\Users>cd..

C:\>cd
C:\

C:\>cd C:\CursoML

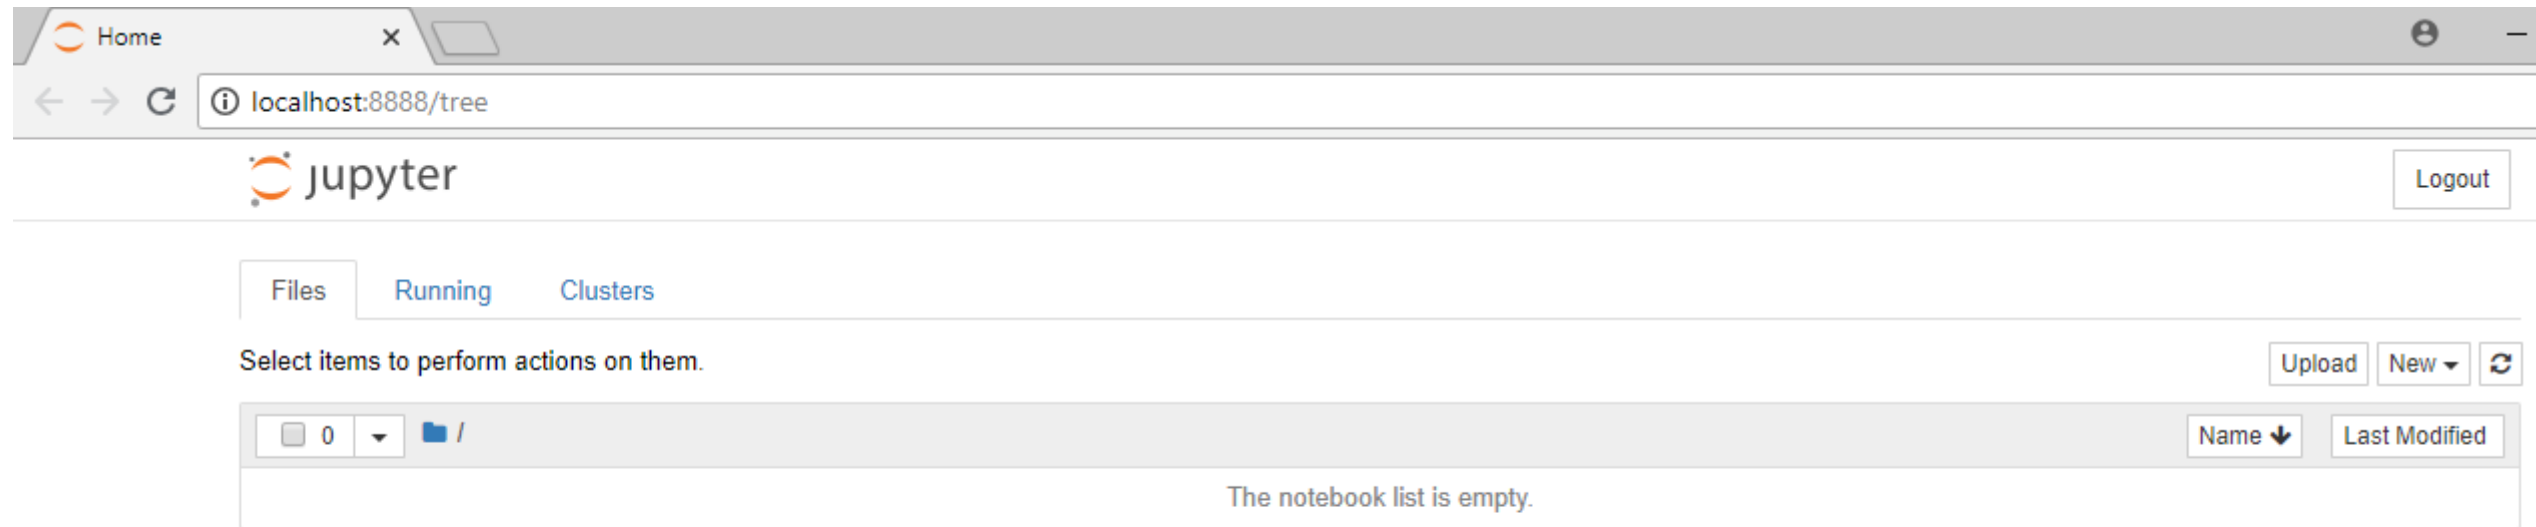
C:\CursoML>jupyter notebook
[I 23:13:18.960 NotebookApp] JupyterLab beta preview extension loading
JupyterLab
[I 23:13:18.961 NotebookApp] JupyterLab application directory is
[W 23:13:19.074 NotebookApp] Error loading server extension jupyterlab
Traceback (most recent call last):
```



pythonTM



Obtenemos:



The screenshot displays the JupyterLab web interface in a browser window. The browser's address bar shows the URL `localhost:8888/tree`. The JupyterLab header includes the logo, the text "jupyter", and a "Logout" button. Below the header, there are three tabs: "Files" (selected), "Running", and "Clusters". A message states "Select items to perform actions on them." To the right of this message are buttons for "Upload", "New" (with a dropdown arrow), and a refresh icon. Below the message, a file browser shows the root directory "/" with a count of "0" items. To the right of the file browser are two columns: "Name" with a downward arrow and "Last Modified". The main content area displays the message "The notebook list is empty."

Home x

localhost:8888/tree

jupyter Logout

Files Running Clusters

Select items to perform actions on them.

Upload New ↕ ↻

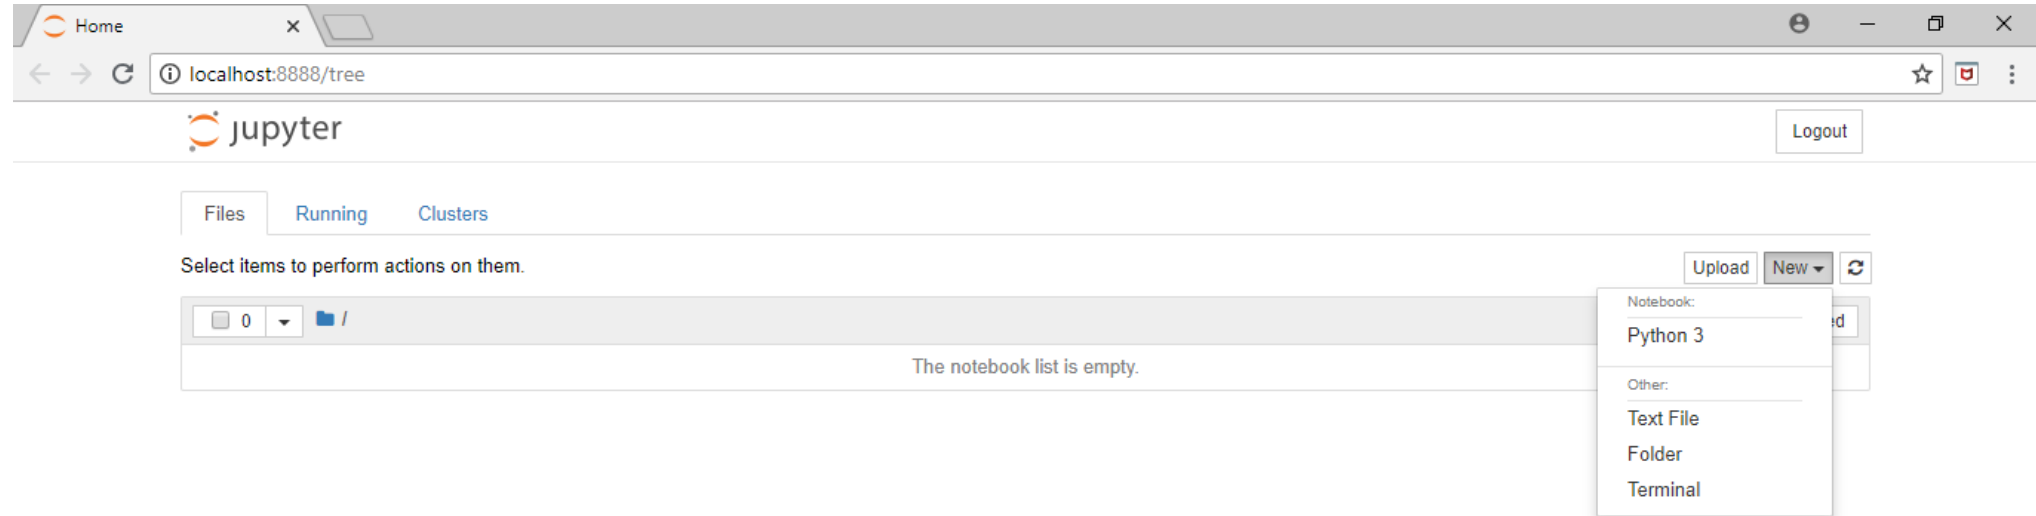
0 ▾ /

Name ↓ Last Modified

The notebook list is empty.

Para crear un block de notas

Se hace
clic en
New y se
elige
Python 3



El block de notas


En el block de notas
tenemos distintos
tipos de celdas
como:

Code

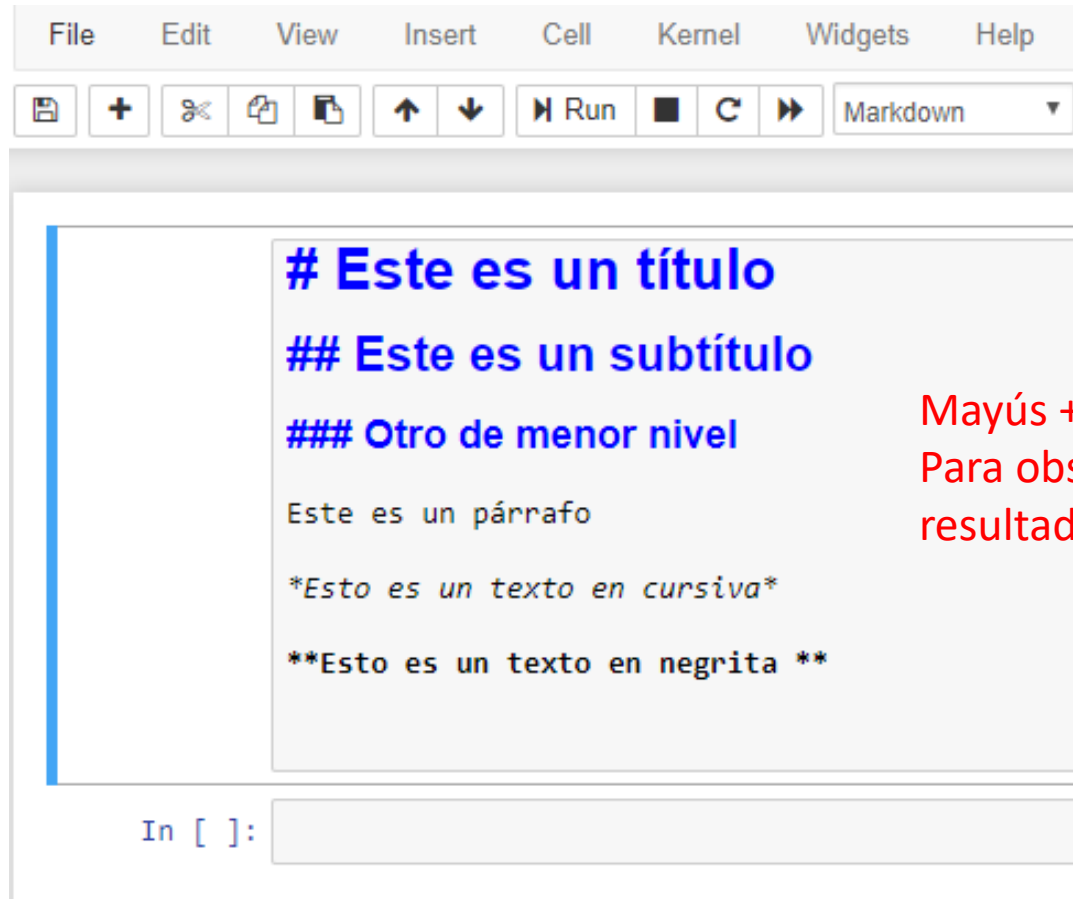
Markdown

Raw NBConvert

Heading



Celda Markdown



The image shows a Jupyter Notebook interface with a menu bar (File, Edit, View, Insert, Cell, Kernel, Widgets, Help) and a toolbar with icons for saving, adding, deleting, copying, pasting, and running. The selected cell is a Markdown cell, indicated by the 'Markdown' dropdown in the toolbar. The cell content is as follows:

```
# Este es un título
## Este es un subtítulo
### Otro de menor nivel

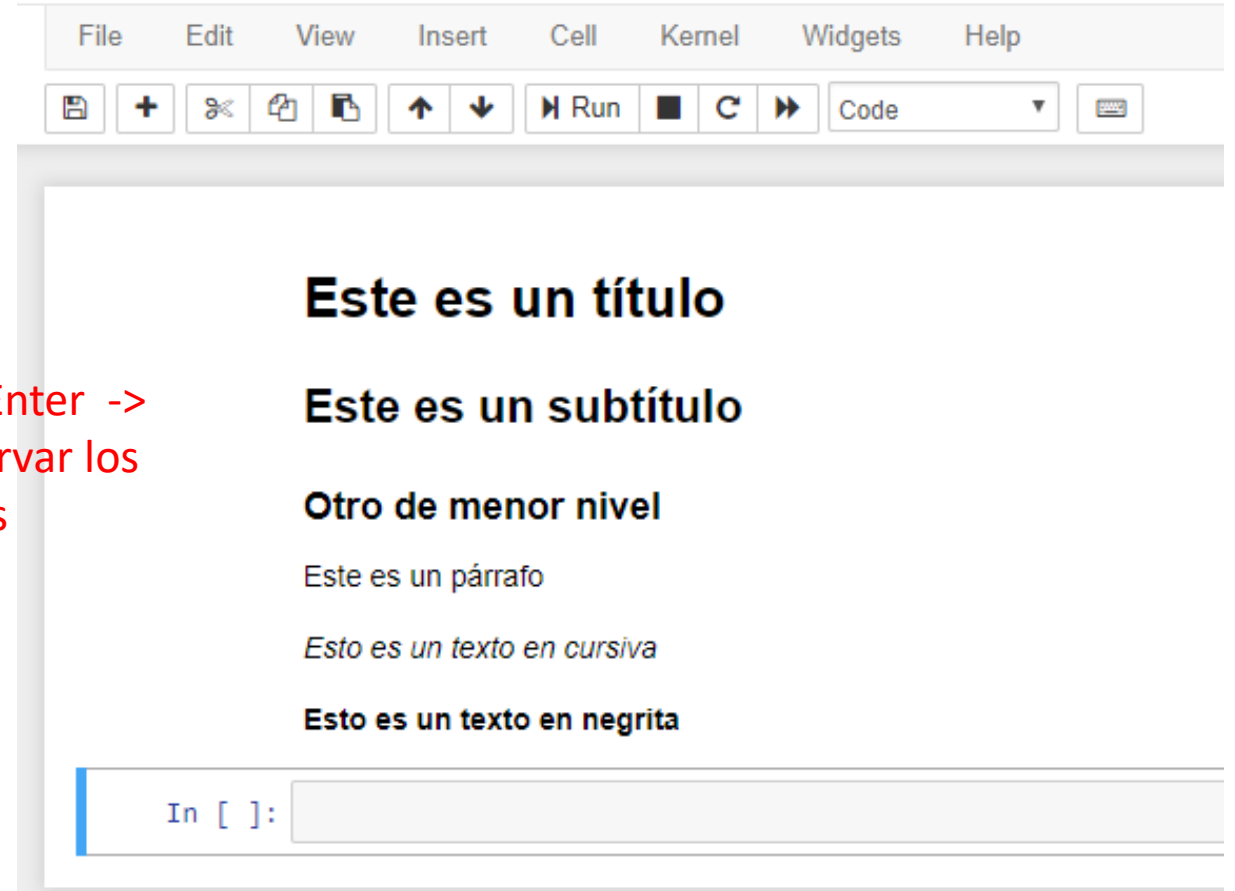
Este es un párrafo

*Esto es un texto en cursiva*

**Esto es un texto en negrita **
```

Below the cell, the prompt 'In []:' is visible next to an empty input field.

Mayús + Enter ->
Para observar los
resultados



The image shows the same Jupyter Notebook interface, but the cell is now in 'Code' mode, as indicated by the 'Code' dropdown in the toolbar. The rendered output of the Markdown cell is displayed:

Este es un título

Este es un subtítulo

Otro de menor nivel

Este es un párrafo

Esto es un texto en cursiva

Esto es un texto en negrita

Below the cell, the prompt 'In []:' is visible next to an empty input field.

Celda Code

En una celda
Code se puede
ejecutar y
probar código
Python

